

Universidad – Ingeniería de Sistemas

Matemáticas Computacionales

Detección de Anomalías en Tráfico de
Red
mediante Modelos de Espacio de
Estados
y Análisis Espectral

Documento Técnico – Parcial II

Docente: Udualdo Herrera PhD (c)

Grupo N.^o –

24 de abril de 2026

Índice

1. Bloque 1 — Entendimiento matemático y formulación	2
1.1. 1.1 Modelado en el dominio temporal	2
1.1.1. Sistema continuo y discretización	2
1.1.2. Garantía de estabilidad	2
1.1.3. Complejidad computacional	3
1.1.4. Comparación con redes recurrentes clásicas	3
1.2. 1.2 Selección dependiente de la entrada	3
1.2.1. Formulación clásica vs. selectiva	3
1.2.2. Beneficio de la selección	4
1.3. 1.3 Dominio frecuencial	4
1.3.1. Transformada de Fourier continua y discreta	4
1.3.2. Propiedad de simetría conjugada	4
1.3.3. Mecanismo de extracción de features espectrales	4
1.4. 1.4 Fusión ponderada	5
1.5. 1.5 Arquitectura completa	6
1.6. 1.6 Hiperparámetros	6
1.7. 1.7 Filtro de Kalman como post-procesamiento	7
1.7.1. Motivación	7
1.7.2. Modelo de espacio de estados escalar	7
1.7.3. Derivación de las ecuaciones de Kalman	7
1.7.4. Análisis de casos límite	8
2. Bloque 3 — Evaluación, comparación y análisis	8
2.1. 3.1 Métricas empleadas	8
2.2. 3.2 Tabla comparativa	9
2.3. 3.3 Discusión de resultados	9
3. Conclusiones	10

1. Bloque 1 — Entendimiento matemático y formulación

1.1. 1.1 Modelado en el dominio temporal

1.1.1. Sistema continuo y discretización

Partimos del sistema dinámico lineal invariante en el tiempo (LTI) en tiempo continuo:

$$\mathbf{x}'(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t), \quad (1)$$

$$\mathbf{y}(t) = \mathbf{C} \mathbf{x}(t) + \mathbf{D} \mathbf{u}(t), \quad (2)$$

donde $\mathbf{x}(t) \in \mathbb{R}^N$ es el vector de estado, $\mathbf{u}(t) \in \mathbb{R}^D$ la entrada y $\mathbf{y}(t) \in \mathbb{R}^D$ la salida.

Discretización Zero-Order Hold (ZOH). La ZOH asume que $\mathbf{u}(t)$ permanece constante en el intervalo $[k\Delta t, (k+1)\Delta t)$. La solución exacta de (1) es:

$$\mathbf{x}(t) = e^{\mathbf{A}_c t} \mathbf{x}(0) + \int_0^t e^{\mathbf{A}_c(t-\tau)} \mathbf{B}_c \mathbf{u}(\tau) d\tau.$$

Evaluando en $t = (k+1)\Delta t$ y aplicando la hipótesis ZOH:

$$\boxed{\bar{\mathbf{A}} = e^{\mathbf{A}_c \Delta t}, \quad \bar{\mathbf{B}} = \mathbf{A}_c^{-1} (e^{\mathbf{A}_c \Delta t} - \mathbf{I}) \mathbf{B}_c.} \quad (3)$$

La recurrencia discreta resultante es:

$$\mathbf{x}_{k+1} = \bar{\mathbf{A}} \mathbf{x}_k + \bar{\mathbf{B}} \mathbf{u}_k, \quad (4)$$

$$\mathbf{y}_k = \mathbf{C} \mathbf{x}_k + \mathbf{D} \mathbf{u}_k. \quad (5)$$

Discretización de Euler. Aproximando $\mathbf{x}'(t) \approx (\mathbf{x}_{k+1} - \mathbf{x}_k)/\Delta t$:

$$\bar{\mathbf{A}}^{\text{Euler}} = \mathbf{I} + \Delta t \mathbf{A}_c, \quad \bar{\mathbf{B}}^{\text{Euler}} = \Delta t \mathbf{B}_c. \quad (6)$$

Euler es de primer orden y puede introducir inestabilidad para Δt grande, mientras que ZOH es exacto y preserva la estabilidad del sistema continuo.

1.1.2. Garantía de estabilidad

Proposición 1. Sea $\mathbf{A}_c = -\text{diag}(\lambda_1, \dots, \lambda_N)$ con $\lambda_i > 0$. Entonces $\bar{\mathbf{A}}^{\text{ZOH}} = \text{diag}(e^{-\lambda_1 \Delta t}, \dots, e^{-\lambda_N \Delta t})$ tiene todos sus valores propios en $(0, 1)$ para cualquier $\Delta t > 0$.

Demostración. Dado que $\lambda_i > 0$ y $\Delta t > 0$, tenemos $e^{-\lambda_i \Delta t} \in (0, 1)$. □

Observación 1 (Condición espectral para estabilidad discreta). Un sistema discreto $\mathbf{x}_{k+1} = \bar{\mathbf{A}} \mathbf{x}_k$ es asintóticamente estable si y sólo si todos los valores propios de $\bar{\mathbf{A}}$ tienen módulo estrictamente menor que 1:

$$\rho(\bar{\mathbf{A}}) := \max_i |\mu_i| < 1,$$

donde μ_i son los eigenvalores de $\bar{\mathbf{A}}$. Para la parametrización diagonal, esto se satisface automáticamente ya que cada $\mu_i = e^{-\lambda_i \Delta t} \in (0, 1) \subset \mathbb{D}$.

1.1.3. Complejidad computacional

La recurrencia (4) se evalúa secuencialmente para $k = 1, \dots, L$:

- Costo por paso: $\mathcal{O}(D \cdot N)$ (producto diagonal).
- Costo total sobre la secuencia de longitud L : $\mathcal{O}(L \cdot D \cdot N)$ — **lineal en L** .

Esto contrasta con los Transformers estándar, cuya atención cuadrática $\mathcal{O}(L^2)$ los hace prohibitivos para secuencias largas.

1.1.4. Comparación con redes recurrentes clásicas

Las LSTM y GRU también tienen complejidad lineal en L , pero sufren el **problema del gradiente desvaneciente/explosivo** durante la retropropagación a través del tiempo (BPTT):

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}_1} = \prod_{t=2}^T \frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-1}} \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{h}_T}.$$

Si los Jacobianos $\partial \mathbf{h}_t / \partial \mathbf{h}_{t-1}$ tienen norma espectral < 1 , el producto colapsa a **cero** (desvanecimiento); si es > 1 , **diverge** (explosión).

Las LSTM mitigan esto con puertas aprendibles, pero el problema persiste para T muy grande. El SSM con $\bar{\mathbf{A}} = \text{diag}(e^{-\lambda_i \Delta t})$ evita el problema porque:

1. Los gradientes fluyen directamente a través de la diagonal de $\bar{\mathbf{A}}$, cuyos valores son fijos y estables en $(0, 1)$.
2. No hay no-linealidades recurrentes: el estado oculto es lineal, por lo que el gradiente a través de t pasos decae *controladamente* como $\prod_t e^{-\lambda_i \Delta t}$.

1.2. Selección dependiente de la entrada

1.2.1. Formulación clásica vs. selectiva

En el SSM clásico los parámetros $\mathbf{A}, \mathbf{B}, \mathbf{C}, \Delta$ son *independientes* de la entrada. Proponemos hacer que $\Delta_t, \mathbf{B}_t$ y $\mathbf{C}_t$ sean proyecciones lineales de $\mathbf{u}_t$:

$$\Delta_t = \text{softplus}(\mathbf{W}_\Delta \mathbf{u}_t + \mathbf{b}_\Delta) \in \mathbb{R}^D, \quad (7)$$

$$\mathbf{B}_t = \mathbf{W}_B \mathbf{u}_t \in \mathbb{R}^N, \quad (8)$$

$$\mathbf{C}_t = \mathbf{W}_C \mathbf{u}_t \in \mathbb{R}^N, \quad (9)$$

donde $\mathbf{W}_\Delta \in \mathbb{R}^{D \times D}$, $\mathbf{W}_B, \mathbf{W}_C \in \mathbb{R}^{N \times D}$ son parámetros aprendibles.

La discretización ZOH resultante es:

$$\bar{\mathbf{A}}_t = \exp(\Delta_t \odot \mathbf{A}) \in \mathbb{R}^{D \times N}, \quad (10)$$

$$\bar{\mathbf{B}}_t = \frac{\bar{\mathbf{A}}_t - \mathbf{I}}{\mathbf{A}} \odot \mathbf{B}_t \in \mathbb{R}^{D \times N}, \quad (11)$$

y la recurrencia selectiva es:

$$\mathbf{h}_t = \bar{\mathbf{A}}_t \odot \mathbf{h}_{t-1} + \bar{\mathbf{B}}_t, \quad y_t^{(d)} = \sum_{n=1}^N C_t^{(n)} h_t^{(d,n)}. \quad (12)$$

1.2.2. Beneficio de la selección

La dependencia de Δ_t , $\mathbf{B}_t$ y $\mathbf{C}_t$ en $\mathbf{u}_t$ otorga al modelo la capacidad de **selección de contenido**:

- Δ_t **grande**: el factor $e^{-\lambda_i \Delta_t}$ se acerca a 0, lo que *reinicia* el estado oculto (olvido del pasado). Equivale a «presionar el borrador» cuando la entrada es informativa.
- Δ_t **pequeño**: $e^{-\lambda_i \Delta_t} \approx 1$, por lo que el estado se mantiene casi intacto (memoria fuerte).
- $\mathbf{B}_t$ controla *cuánto* de la entrada actual se escribe en el estado.
- $\mathbf{C}_t$ controla *qué* parte del estado se lee para generar la salida.

En el contexto de detección de anomalías, el modelo puede aprender a “ignorar” el tráfico normal repetitivo mientras almacena patrones de ataque que difieren del comportamiento habitual.

1.3. Dominio frecuencial

1.3.1. Transformada de Fourier continua y discreta

La **Transformada de Fourier continua** (CFT) de una señal $x(t)$ es:

$$X(f) = \int_{-\infty}^{+\infty} x(t) e^{-j2\pi ft} dt. \quad (13)$$

Su análoga discreta (**DFT**) para una señal $x[n]$, $n = 0, \dots, N-1$:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad k = 0, \dots, N-1. \quad (14)$$

1.3.2. Propiedad de simetría conjugada

Proposición 2. Si $x[n] \in \mathbb{R}$ para todo n , entonces $X[N-k] = X^*[k]$ (conjugado complejo). Por tanto, para una señal real de longitud L , los coeficientes $X[k]$ con $k > \lfloor L/2 \rfloor$ son completamente determinados por $X[0], \dots, X[\lfloor L/2 \rfloor]$. Sólo se necesitan $\lfloor L/2 \rfloor + 1$ coeficientes complejos independientes.

Demostración. Calculemos $X[L-k]$:

$$X[L-k] = \sum_{n=0}^{L-1} x[n] e^{-j2\pi(L-k)n/L} = \sum_{n=0}^{L-1} x[n] e^{j2\pi kn/L} = \left(\sum_{n=0}^{L-1} x[n] e^{-j2\pi kn/L} \right)^* = X^*[k].$$

□

Esto justifica el uso de `torch.fft.rfft`, que devuelve $\lfloor L/2 \rfloor + 1$ coeficientes complejos (los llamados *one-sided spectrum*).

1.3.3. Mecanismo de extracción de features espectrales

Dado $\mathbf{u} \in \mathbb{R}^{L \times D}$ (una ventana temporal):

Paso (a) — rFFT a lo largo del eje temporal:

$$X[k, d] = \sum_{n=0}^{L-1} u[n, d] e^{-j2\pi kn/L}, \quad k = 0, \dots, \frac{L}{2}, \quad d = 1, \dots, D. \quad (15)$$

Resultado: $X \in \mathbb{C}^{(L/2+1) \times D}$.

Paso (b) — Selección de las K componentes de mayor magnitud:

$$\mathcal{K} = \underset{k}{\operatorname{argtop-K}} \left(\frac{1}{BD} \sum_{b,d} |X_b[k, d]| \right). \quad (16)$$

$X_K = X[\mathcal{K}, :] \in \mathbb{C}^{K \times D}$.

Paso (c) — Filtro complejo aprendible:

$$W = W_{\text{re}} + j W_{\text{im}}, \quad W \in \mathbb{C}^{K \times D}, \quad \tilde{X}_K = W \odot X_K. \quad (17)$$

Paso (d) — iRFFT de vuelta al dominio temporal:

$$\hat{X}_{\text{out}}[k, d] = \begin{cases} \tilde{X}_K[i, d] & \text{si } k = \mathcal{K}[i], \\ 0 & \text{en otro caso.} \end{cases} \quad \hat{\mathbf{u}} = \text{iRFFT}(\hat{X}_{\text{out}}) \in \mathbb{R}^{L \times D}. \quad (18)$$

1.4. 1.4 Fusión ponderada

Definimos la fusión elemento a elemento de las representaciones temporal y espectral:

$$\mathbf{z}_t = \boldsymbol{\alpha} \odot \mathbf{x}_t^{(\text{temp})} + \boldsymbol{\beta} \odot \mathbf{x}^{(f)}, \quad \boldsymbol{\alpha}, \boldsymbol{\beta} \in \mathbb{R}^D \text{ aprendibles.} \quad (19)$$

¿Por qué producto elemento a elemento $\odot$ y no un escalar? Un escalar $\alpha \in \mathbb{R}$ aplicaría el *mismo* peso a cada dimensión de la representación. Con $\boldsymbol{\alpha} \in \mathbb{R}^D$, el modelo puede asignar pesos *distintos* a cada característica d : por ejemplo, ponderar más la representación temporal en las dimensiones de bytes transmitidos (que evoluciona rápidamente) y más la espectral en los patrones de sincronización periódica (frecuencias dominantes).

Rol de la inicialización. Si se inicializan $\boldsymbol{\alpha} = \boldsymbol{\beta} = 0,5$, la fusión comienza como un promedio igualitario. El gradiente descenso puede luego especializarlos. Una inicialización más extrema ($\boldsymbol{\alpha} = \mathbf{1}, \boldsymbol{\beta} = \mathbf{0}$) podría suprimir la rama espectral desde el inicio, dificultando el aprendizaje de patrones periódicos.

¿Qué pasaría si $\boldsymbol{\alpha} = \boldsymbol{\beta} = \mathbf{1}$ (fijos)? La fusión degeneraría en una simple *suma*: $\mathbf{z}_t = \mathbf{x}_t^{(\text{temp})} + \mathbf{x}^{(f)}$. Esto impediría al modelo decidir cuándo confiar más en la rama temporal o en la espectral, perdiendo la adaptabilidad que justifica la arquitectura híbrida.

1.5. 1.5 Arquitectura completa




Figura 1: Diagrama de la arquitectura completa del *AnomalyDetector*. Las líneas punteadas delimitan el bloque encoder que se repite n_{layers} veces.

¿Por qué la rama espectral va en paralelo y no en serie? Si la rama espectral estuviera *en serie* con la temporal, la representación espectral dependería del estado del SSM, perdiendo su carácter independiente. La disposición en *paralelo* permite al modelo explotar simultáneamente dos tipos de información ortogonal:

- **Rama temporal:** evolución secuencial, dependencias de largo plazo, correlaciones causales.
- **Rama espectral:** estructura periódica de la señal, frecuencias dominantes del tráfico.

La capa de fusión decide con cuánto peso combinarlos en función de la instancia concreta.

1.6. 1.6 Hiperparámetros

La Tabla 1 clasifica los hiperparámetros del modelo según su efecto.

Cuadro 1: Hiperparámetros del sistema, clasificación y valores iniciales.

Hiperparámetro	Categoría	Valor inicial	Justificación
D (d_model)	Capacidad	64	Suficiente para 49 features; no sobreajusta.
N (d_state)	Capacidad	16	Cubre dependencias de ~ 100 pasos.
K (top_k)	Capacidad	16	Captura los primeros armónicos periódicos.
n_{layers}	Capacidad	2	Profundidad mínima viable sin sobreajuste.
k (kernel_size)	Capacidad	3	Contexto local para conv causal.
η (learning rate)	Estabilidad	10^{-3}	Estándar Adam; ajustar con scheduler.
clip_grad_norm	Estabilidad	1.0	Previene explosión en BPTT.
dropout	Estabilidad	0.1	Regularización leve.
L (seq_len)	Costo comp.	64	$\mathcal{O}(L \cdot D \cdot N)$; modular.
batch_size	Costo comp.	32	Balanceo GPU/CPU; gradiente estable.
stride	Costo comp.	32	50 % solapamiento; dobla el dataset.

1.7. 1.7 Filtro de Kalman como post-procesamiento

1.7.1. Motivación

El modelo produce para cada ventana t una probabilidad $p_t \in [0, 1]$ de que sea anómala. En la práctica, p_t oscila de ventana a ventana aunque el estado subyacente (ataque activo o tráfico normal) cambia lentamente. El filtro de Kalman estima el estado latente s_t suavizando el ruido de observación.

1.7.2. Modelo de espacio de estados escalar

$$s_{t+1} = s_t + w_t, \quad w_t \sim \mathcal{N}(0, \sigma_w^2), \quad (20)$$

$$p_t = s_t + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_v^2). \quad (21)$$

Este modelo de **caminata aleatoria** establece que el estado verdadero evoluciona con pequeñas perturbaciones gaussianas (controladas por σ_w^2) y que la observación agrega ruido gaussiano adicional (controlado por σ_v^2).

1.7.3. Derivación de las ecuaciones de Kalman

Sea $\hat{s}_{t|t-1}$ la estimación predicha y $P_{t|t-1}$ su varianza de error a priori.

Paso de predicción. Dado que $s_{t+1} = s_t + w_t$ con w_t independiente:

$$\hat{s}_{t|t-1} = \hat{s}_{t-1|t-1}, \quad (22)$$

$$P_{t|t-1} = P_{t-1|t-1} + \sigma_w^2. \quad (23)$$

Ganancia de Kalman. La ganancia óptima que minimiza la varianza posterior bajo supuestos gaussianos es:

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + \sigma_v^2} \in (0, 1). \quad (24)$$

Paso de actualización. La innovación es $\nu_t = p_t - \hat{s}_{t|t-1}$. La estimación a posteriori:

$$\hat{s}_{t|t} = \hat{s}_{t|t-1} + K_t \nu_t, \quad (25)$$

$$P_{t|t} = (1 - K_t) P_{t|t-1}. \quad (26)$$

1.7.4. Análisis de casos límite

Caso $\sigma_w^2 \rightarrow 0$ (sistema muy estable). $P_{t|t-1} = P_{t-1|t-1}$ no crece; al iterar, $P_{t|t} \rightarrow 0$ y por ende

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + \sigma_v^2} \xrightarrow{\sigma_w^2 \rightarrow 0} 0.$$

El filtro **ignora las observaciones**: confía ciegamente en su predicción anterior. Útil cuando el estado varía muy poco, pero peligroso si aparece un ataque repentino.

Caso $\sigma_w^2 \rightarrow \infty$ (sistema muy volátil). $P_{t|t-1} \rightarrow \infty$, luego:

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + \sigma_v^2} \xrightarrow{\sigma_w^2 \rightarrow \infty} 1.$$

El filtro **adopta completamente la observación**: $\hat{s}_{t|t} = p_t$. Sin suavizado alguno, equivale a no usar el filtro.

Relación σ_w^2/σ_v^2 y tipo de suavizado.

- $\sigma_w^2/\sigma_v^2 \ll 1$: suavizado *agresivo* (Kalman confía poco en las observaciones; estima un estado lentamente cambiante).
- $\sigma_w^2/\sigma_v^2 \gg 1$: seguimiento *rápido* (Kalman actualiza fuerte con cada observación; poca inercia).

En la práctica, para un detector de anomalías se prefiere σ_w^2 pequeño (el estado del sistema—“ataque activo”—cambia lentamente) y σ_v^2 moderado (el modelo tiene cierto ruido de predicción).

2. Bloque 3 — Evaluación, comparación y análisis

2.1. 3.1 Métricas empleadas

Accuracy $\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN}.$

Fracción de clasificaciones correctas. Poco informativa en datasets desbalanceados.

Recall (macro) $\text{Rec} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$

Capacidad de detectar ataques (clase minoritaria). Métrica crítica en seguridad de redes.

F1 (macro) $F_1 = \frac{1}{2} \left(\frac{2TP}{2TP + FP + FN} + \frac{2TN}{2TN + FN + FP} \right)$.
Media armónica de precisión y recall; equilibrio entre ambos.

MAE $MAE = \frac{1}{N} \sum_{t=1}^N |y_t - p_t|$. Error absoluto medio entre la probabilidad predicha y la etiqueta.

MSE $MSE = \frac{1}{N} \sum_{t=1}^N (y_t - p_t)^2$. Penaliza más los errores grandes.

2.2. 3.2 Tabla comparativa

Cuadro 2: Comparación de métricas entre el modelo baseline y variantes con filtro de Kalman. Los resultados se completarán con los valores reales tras la ejecución del notebook.

Variante	Accuracy	Recall	F1	MAE	MSE
Baseline (sin Kalman)	–	–	–	–	–
Kalman ($\sigma_w^2 = 10^{-4}$, $\sigma_v^2 = 10^{-2}$)	–	–	–	–	–
Kalman ($\sigma_w^2 = 10^{-3}$, $\sigma_v^2 = 10^{-2}$)	–	–	–	–	–
Kalman ($\sigma_w^2 = 10^{-2}$, $\sigma_v^2 = 10^{-2}$)	–	–	–	–	–

2.3. 3.3 Discusión de resultados

¿Mejoró el Kalman las métricas? Se espera que el filtro de Kalman mejore principalmente el **MAE** y el **MSE** al reducir las oscilaciones de alta frecuencia en la secuencia de probabilidades predicha. En cuanto a Accuracy, Recall y F1, el efecto depende del nivel de ruido del modelo: si el modelo ya es confiable, el suavizado puede degradar el Recall al retardar la detección de ataques repentinos; si el modelo es muy ruidoso, el suavizado reduce los falsos positivos mejorando la Precision y, en consecuencia, el F1.

Trade-off precisión / recall con Kalman. El filtro introduce **inercia temporal**: cuando el estado pasa de normal a ataque (o viceversa), el filtro tarda varios pasos en actualizar su estimación. Esto implica:

- **Menos falsos positivos** (mejor precisión): el filtro no reacciona ante destellos de probabilidad alta aislados.
- **Más falsos negativos** (peor recall): el filtro demora el reconocimiento de un ataque recién iniciado.

El trade-off es inherente a cualquier sistema de suavizado causal.

Limitaciones del modelo de caminata aleatoria. El modelo $s_{t+1} = s_t + w_t$ asume que el estado verdadero tiene *deriva nula* y que los cambios son gaussianos i.i.d. Esto es una aproximación razonable para ataques de larga duración (DDoS sostenido, escaneos lentos), pero falla para:

- **Ataques de muy corta duración** (*flash attacks*): el estado cambia y regresa en pocos pasos, más rápido que la constante de tiempo del filtro.
- **Ataques periódicos** (*beaconing*): presentan una estructura no gaussiana que no es capturada por el modelo de ruido blanco.
- **Distribución bimodal** de p_t : el estado verdadero es binario (0/1), no gaussiano; el filtro de Kalman asume gaussianidad.

Mejoras propuestas si hubiera más tiempo.

1. **Kalman con modelo de transición no lineal** (UKF / EKF): modelar explícitamente la naturaleza binaria del estado y las transiciones de fase.
2. **Implementar la convolución SSM en el dominio frecuencial** (transformada de convolution global): reduciría la complejidad de $\mathcal{O}(LDN)$ a $\mathcal{O}(L \log L \cdot D)$ y permitiría secuencias de miles de pasos.
3. **Pre-entrenamiento no supervisado** sobre el tráfico sin etiqueta: el dataset UNSW-NB15 es relativamente pequeño; un autoencoder SSM pre-entrenado en tráfico sin etiquetar mejoraría la representación y generalizaría mejor a ataques no vistos.

3. Conclusiones

Se diseñó una arquitectura híbrida que integra un modelo de espacio de estados selectivo (de complejidad lineal en la longitud de secuencia) con una rama espectral basada en la transformada discreta de Fourier. La fusión adaptativa $\mathbf{z} = \boldsymbol{\alpha} \odot \mathbf{x}_t + \boldsymbol{\beta} \odot \mathbf{x}^{(f)}$ permite al modelo ponderar autónomamente la información temporal y periódica. El filtro de Kalman escalar opera como post-procesador reduciendo el ruido de predicción, con un trade-off entre suavizado y latencia de detección que depende del cociente σ_w^2 / σ_v^2 . Los resultados del notebook confirmarán qué configuración de Kalman ofrece el mejor balance para el dataset UNSW-NB15.

Referencias

- [1] A. Gu, K. Goel, C. Ré, *Efficiently Modeling Long Sequences with Structured State Spaces*, ICLR 2022.
- [2] A. Gu, T. Dao, *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*, arXiv:2312.00752, 2023.
- [3] R. E. Kalman, *A New Approach to Linear Filtering and Prediction Problems*, ASME J. Basic Eng., 82(1):35–45, 1960.

- [4] N. Moustafa, J. Slay, *UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems*, MilCIS, 2015.
- [5] A. V. Oppenheim, R. W. Schaffer, *Discrete-Time Signal Processing*, 3rd ed., Prentice Hall, 2009.