

Deteccion de anomalias en trafico de red mediante modelos de espacio de estados, analisis espectral y filtro de Kalman

Equipo: CARLOS JOSE BALDIRIS MARTELO, JOSE GUERRA DE LAS AGUAS, DIEGO HERNANDEZ CARABALLO
JEFFERSON FLOREZ VANEGAS, ANDREYS SUMOSA GODOY
Parcial II Corte - Matematicas Computacionales

Resumen

Este documento presenta el diseno matematico, la arquitectura y el protocolo experimental de un sistema de deteccion de anomalias sobre el conjunto UNSW-NB15. La propuesta combina una rama temporal basada en un modelo de espacio de estados selectivo, una rama frecuencial basada en la transformada discreta de Fourier, una fusion aprendible por canal y un filtro de Kalman escalar como post-procesamiento de las probabilidades de anomalia. El sistema clasifica ventanas temporales multivariadas como normales o anomalas.

Indice

1 Definicion del problema	2
2 Bloque 1: Entendimiento matematico y formulacion	2
2.1 Modelado en el dominio temporal	2
2.1.1 Discretizacion por zero-order hold	2
2.1.2 Discretizacion por Euler	3
2.1.3 Estabilidad	3
2.1.4 Costo computacional	4
2.1.5 Comparacion con LSTM y GRU	4
2.2 Seleccion dependiente de la entrada	4
2.3 Dominio frecuencial	5
2.3.1 Extractor espectral propuesto	5
2.4 Fusion ponderada	6
2.5 Arquitectura completa	6
2.6 Hiperparametros	6
2.7 Filtro de Kalman como post-procesamiento	7
2.7.1 Prediccion	7
2.7.2 Ganancia de Kalman	7
2.7.3 Actualizacion	7
3 Bloque 2: Implementacion	8
4 Bloque 3: Evaluacion, comparacion y analisis	8
4.1 Metricas	8
4.2 Tabla comparativa	8
4.3 Criterios para interpretar si los resultados son flojos	9
4.4 Discusion esperada	9

1 Definicion del problema

Sea una secuencia multivariada de trafico de red

$$U = (u_1, u_2, \dots, u_T), \quad u_t \in \mathbb{R}^F,$$

donde cada vector contiene características numéricas y categóricas codificadas de un flujo o registro de red. El objetivo es construir ventanas

$$W_i = (u_i, u_{i+1}, \dots, u_{i+L-1}) \in \mathbb{R}^{L \times F}$$

y asignarles una etiqueta binaria

$$y_i \in \{0, 1\},$$

donde 0 representa tráfico normal y 1 representa tráfico anómalo o ataque.

La decisión inicial usada en el proyecto es:

- Dataset: UNSW-NB15.
- Archivos: UNSW_NB15_training-set.csv y UNSW_NB15_testing-set.csv.
- Etiqueta: label.
- Longitud de ventana: $L = 32$.
- Etiqueta de ventana: anómala si contiene al menos un registro con label=1.
- Framework: PyTorch.

2 Bloque 1: Entendimiento matemático y formulación

2.1 Modelado en el dominio temporal

Partimos de un sistema dinámico lineal en tiempo continuo:

$$x'(t) = A_c x(t) + B_c u(t), \tag{1}$$

$$y(t) = C x(t) + D u(t), \tag{2}$$

donde $x(t) \in \mathbb{R}^N$ es el estado interno, $u(t) \in \mathbb{R}^F$ es la entrada, $y(t)$ es la salida, A_c es la matriz de transición continua, B_c la matriz de entrada, C la matriz de lectura y D el término de salto directo.

2.1.1 Discretización por zero-order hold

Bajo el supuesto zero-order hold, la entrada es constante durante cada intervalo $[k\Delta, (k+1)\Delta)$:

$$u(t) = u_k, \quad t \in [k\Delta, (k+1)\Delta).$$

La solución de la ecuación diferencial entre $k\Delta$ y $(k+1)\Delta$ es:

$$x((k+1)\Delta) = e^{\Delta A_c} x(k\Delta) + \int_0^\Delta e^{(\Delta-\tau)A_c} B_c u_k d\tau.$$

Definiendo $x_k = x(k\Delta)$ se obtiene:

$$x_{k+1} = A_d x_k + B_d u_k, \tag{3}$$

$$y_k = C x_k + D u_k, \tag{4}$$

con

$$A_d = e^{\Delta A_c}, \quad (5)$$

$$B_d = \int_0^{\Delta} e^{(\Delta-\tau)A_c} B_c d\tau. \quad (6)$$

Si A_c es invertible, tambien puede escribirse:

$$B_d = A_c^{-1} (e^{\Delta A_c} - I) B_c.$$

Esta forma es exacta para entradas constantes por intervalo.

2.1.2 Discretizacion por Euler

La aproximacion de Euler hacia adelante usa:

$$x'(t) \approx \frac{x_{k+1} - x_k}{\Delta}.$$

Sustituyendo en la ecuacion continua:

$$\frac{x_{k+1} - x_k}{\Delta} = A_c x_k + B_c u_k.$$

Por tanto:

$$x_{k+1} = x_k + \Delta A_c x_k + \Delta B_c u_k, \quad (7)$$

$$x_{k+1} = (I + \Delta A_c) x_k + \Delta B_c u_k. \quad (8)$$

La version discreta por Euler queda:

$$A_d^{Euler} = I + \Delta A_c, \quad (9)$$

$$B_d^{Euler} = \Delta B_c. \quad (10)$$

2.1.3 Estabilidad

Se propone la parametrizacion:

$$A_c = -\text{diag}(\lambda_1, \dots, \lambda_N), \quad \lambda_i > 0.$$

Los autovalores continuos son $-\lambda_i$, todos negativos. Para ZOH:

$$\mu_i(A_d) = e^{-\Delta \lambda_i}.$$

Como $\Delta > 0$ y $\lambda_i > 0$:

$$0 < e^{-\Delta \lambda_i} < 1.$$

Luego todos los autovalores discretos estan dentro del circulo unitario.

La condicion general de estabilidad discreta es:

$$\rho(A_d) < 1,$$

donde $\rho(A_d)$ es el radio espectral. Para Euler:

$$\mu_i(A_d^{Euler}) = 1 - \Delta \lambda_i.$$

La estabilidad exige:

$$|1 - \Delta \lambda_i| < 1 \quad \Longleftrightarrow \quad 0 < \Delta \lambda_i < 2.$$

Por eso ZOH resulta mas robusta numericamente: preserva la estabilidad para cualquier $\Delta > 0$ si A_c tiene autovalores con parte real negativa.

2.1.4 Costo computacional

Si la longitud de la ventana es L , la dimension del estado es N y el modelo usa D canales internos, la recurrencia selectiva actualiza un estado de tamaño $D \times N$ por paso. El costo por paso es $O(DN)$ y el costo total es:

$$O(LDN).$$

Esto escala linealmente con L , lo cual satisface el requisito de baja complejidad temporal frente a mecanismos cuadráticos como la atención global de un Transformer estándar.

2.1.5 Comparación con LSTM y GRU

Las redes recurrentes tradicionales como LSTM y GRU también procesan secuencias paso a paso, pero durante la retropropagación aparecen productos repetidos de matrices Jacobianas. Si las normas espectrales de esas matrices son menores que uno, el gradiente tiende a desvanecerse; si son mayores que uno, puede explotar. LSTM y GRU mitigan este problema con compuertas, pero no eliminan completamente la dificultad para dependencias muy largas.

En el modelo de espacio de estados propuesto, la estabilidad se incorpora directamente en la parametrización de A_c . Al forzar autovalores continuos negativos y autovalores discretos dentro del círculo unitario, se evita la explosión del estado. Adicionalmente, la selección dependiente de la entrada permite que el modelo aprenda modos lentos o rápidos según la información de cada instante.

2.2 Selección dependiente de la entrada

En una formulación clásica, A , B , C y Δ son fijos. Para hacer el modelo selectivo, mantenemos A estable pero generamos Δ_t , B_t y C_t desde la entrada:

$$\Delta_t = \text{softplus}(W_\Delta u_t + b_\Delta) + \epsilon, \quad (11)$$

$$B_t = \text{reshape}(W_B u_t + b_B), \quad (12)$$

$$C_t = \text{reshape}(W_C u_t + b_C). \quad (13)$$

La constante $\epsilon > 0$ evita pasos temporales nulos. Para cada canal y estado se usa:

$$A = -\exp(A_{\log}),$$

lo que garantiza valores negativos.

La recurrencia queda:

$$\bar{A}_t = \exp(\Delta_t \odot A), \quad (14)$$

$$h_t = \bar{A}_t \odot h_{t-1} + \Delta_t \odot B_t \odot u_t, \quad (15)$$

$$y_t = \sum_{n=1}^N C_{t,n} \odot h_{t,n} + D \odot u_t. \quad (16)$$

Esta modificación le permite al modelo seleccionar información. Si una entrada contiene un patrón importante, puede producir un Δ_t pequeño y modos de memoria lentos para retener información. Si una entrada es ruido o irrelevante, puede producir parámetros que hagan decaer rápidamente el estado. En otras palabras, el modelo aprende que recordar y que descartar.

2.3 Dominio frecuencial

La transformada de Fourier continua de una senal $x(t)$ se define como:

$$X(f) = \int_{-\infty}^{+\infty} x(t)e^{-j2\pi ft} dt.$$

Para una senal discreta $x[n]$ de longitud L , la transformada discreta de Fourier es:

$$X[k] = \sum_{n=0}^{L-1} x[n]e^{-j2\pi kn/L}, \quad k = 0, \dots, L-1.$$

Si $x[n]$ es real, se cumple simetria conjugada:

$$X[L-k] = \overline{X[k]}.$$

Por tanto no hace falta guardar todos los coeficientes complejos. Basta con conservar:

$$\left\lfloor \frac{L}{2} \right\rfloor + 1$$

coeficientes, que es precisamente lo que calcula `torch.fft.rfft`.

2.3.1 Extractor espectral propuesto

Sea $H \in \mathbb{R}^{B \times L \times D}$ una representacion interna. La rama espectral aplica:

1. DFT a lo largo del eje temporal:

$$\mathcal{F} = \text{rFFT}(H) \in \mathbb{C}^{B \times F_r \times D}, \quad F_r = \left\lfloor \frac{L}{2} \right\rfloor + 1.$$

2. Magnitudes:

$$M_{b,k,d} = |\mathcal{F}_{b,k,d}|.$$

3. Seleccin top- K :

$$\Omega_{b,d} = \text{TopK}_k(M_{b,k,d}).$$

Se construye una mascara G :

$$G_{b,k,d} = \begin{cases} 1, & k \in \Omega_{b,d}, \\ 0, & k \notin \Omega_{b,d}. \end{cases}$$

4. Filtrado complejo aprendible:

$$\tilde{\mathcal{F}}_{b,k,d} = G_{b,k,d} \mathcal{F}_{b,k,d} W_{k,d}, \quad W_{k,d} = a_{k,d} + jb_{k,d}.$$

5. Retorno al tiempo:

$$H^{freq} = \text{irFFT}(\tilde{\mathcal{F}}, n = L).$$

Esta rama permite representar periodicidades o ciclos de trafico que pueden no ser evidentes en la recurrencia temporal local.

2.4 Fusion ponderada

Sean H_t^{temp} y H_t^{freq} las representaciones temporal y frecuencial en el instante t . Se propone:

$$z_t = \alpha \odot H_t^{temp} + \beta \odot H_t^{freq},$$


con $\alpha, \beta \in \mathbb{R}^D$ aprendibles.

Se usa producto elemento a elemento porque no todos los canales internos tienen el mismo rol. Algunos canales pueden especializarse en dinamica temporal, otros en ciclos o frecuencias. Un escalar unico obligaria a ponderar toda la rama por igual.

La inicializacion de α y β controla el sesgo inicial. En este proyecto se inicializan en 0.5, dando igual importancia inicial a ambas ramas. Si se fijaran en $\alpha = \beta = 1$, la fusion dejaria de ser adaptativa y el modelo no podria aprender cuanto confiar en cada representacion.

2.5 Arquitectura completa

La arquitectura implementada sigue el esquema:



Tiene sentido colocar la rama frecuencial en paralelo y no en serie porque ambas ramas observan la misma representacion de entrada desde perspectivas complementarias. La rama temporal modela orden, memoria y transiciones; la rama frecuencial extrae periodicidades. Si se pusieran en serie, una rama podria distorsionar o eliminar informacion necesaria para la otra. En paralelo, el mecanismo de fusion decide adaptativamente que informacion conservar.

2.6 Hiperparametros

Hiperparametro	Categoria principal	Valor inicial	Justificacion
L ventana	Costo y memoria	32	Captura contexto corto-medio y es manejable en Colab.
d_{model}	Capacidad y costo	64	Suficiente para una primera version sin hacer pesado el entrenamiento.
N estado SSM	Capacidad y costo	16	Permite memoria interna por canal con costo lineal.
Numero de capas	Capacidad	2	Profundidad moderada para evitar sobreajuste inicial.
Kernel conv local	Capacidad local	3	Captura vecindad inmediata sin costo alto.
Top- K frecuencias	Capacidad espectral	8	Retiene componentes dominantes sin usar todo el espectro.
Dropout	Estabilidad	0.10	Regularizacion moderada.

Hiperparametro	Categoria principal	Valor inicial	Justificacion
Learning rate	Estabilidad	10^{-3}	Valor estandar con Adam.
Batch size	Estabilidad y costo	32	Requerido por el enunciado y viable en GPU T4.
Gradient clipping	Estabilidad	1.0	Reduce riesgo de explosion de gradiente.
Epocas	Entrenamiento	5 minimo	Cumple el minimo y sirve como prueba base.
$q = \sigma_w^2$ Kalman	Suavizado	$10^{-5}, 10^{-4}, 10^{-3}$	Explora de suavizado agresivo a seguimiento rapido.
$r = \sigma_v^2$ Kalman	Ruido observado	10^{-2}	Supone probabilidades ruidosas pero informativas.

2.7 Filtro de Kalman como post-procesamiento

El modelo produce una probabilidad $p_t \in [0, 1]$ para cada ventana. Se asume un estado latente s_t que representa la verdadera probabilidad subyacente de anomalia:

$$s_t = s_{t-1} + w_t, \quad w_t \sim \mathcal{N}(0, \sigma_w^2), \quad (17)$$

$$p_t = s_t + v_t, \quad v_t \sim \mathcal{N}(0, \sigma_v^2). \quad (18)$$

2.7.1 Prediccion

Como el modelo de estado es una caminata aleatoria:

$$\hat{s}_{t|t-1} = \hat{s}_{t-1|t-1}, \quad (19)$$

$$P_{t|t-1} = P_{t-1|t-1} + \sigma_w^2. \quad (20)$$

2.7.2 Ganancia de Kalman

La observacion es directa, con matriz de observacion igual a 1. Por tanto:

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + \sigma_v^2}.$$

2.7.3 Actualizacion

La innovacion es:

$$p_t - \hat{s}_{t|t-1}.$$

Entonces:

$$\hat{s}_{t|t} = \hat{s}_{t|t-1} + K_t (p_t - \hat{s}_{t|t-1}), \quad (21)$$

$$P_{t|t} = (1 - K_t)P_{t|t-1}. \quad (22)$$

Si $\sigma_w^2 \rightarrow 0$, el sistema se considera muy estable. En regimen estacionario, la incertidumbre P tiende a reducirse y $K_t \rightarrow 0$; el filtro confia mas en su estado previo y suaviza agresivamente. Si $\sigma_w^2 \rightarrow \infty$, la incertidumbre de prediccion domina y $K_t \rightarrow 1$; el filtro confia casi completamente en la nueva observacion y sigue cambios rapidos.

3 Bloque 2: Implementacion

El repositorio se organiza en los modulos solicitados:

- `src/model.py`: contiene `SelectiveSSM`, `TemporalBlock`, `SpectralBlock`, `Fusion` y `AnomalyDetector`.
- `src/data.py`: carga CSV, codifica `proto`, `service` y `state`, ajusta `MinMaxScaler` solo con entrenamiento, aplica SMOTE + undersampling y crea ventanas.
- `src/kalman.py`: implementa `KalmanSmoother`.
- `train.py`: ejecuta entrenamiento con Adam, `CrossEntropyLoss`, batch size 32, gradient clipping y seleccion de checkpoint por F1 de validacion.
- `src/evaluate.py`: calcula Accuracy, Recall macro, F1 macro, MAE y MSE.
- `notebook.ipynb`: ejecucion paso a paso.

La carga programatica del modelo queda:

```
model = AnomalyDetector.load('checkpoints/best_model.pt')
prob_anomaly = model.predict_proba(nueva_ventana)
```

4 Bloque 3: Evaluacion, comparacion y analisis

4.1 Metricas

Para cada variante se reportan:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad (23)$$

$$Recall_{macro} = \frac{1}{2} (Recall_0 + Recall_1), \quad (24)$$

$$F1_{macro} = \frac{1}{2} (F1_0 + F1_1), \quad (25)$$

$$MAE = \frac{1}{M} \sum_{i=1}^M |y_i - p_i|, \quad (26)$$

$$MSE = \frac{1}{M} \sum_{i=1}^M (y_i - p_i)^2. \quad (27)$$

4.2 Tabla comparativa

La siguiente tabla debe llenarse con los valores generados en `results/test_metrics.csv` despues de ejecutar el notebook o `train.py`.

Variante	Accuracy	Recall macro	F1 macro	MAE	MSE
Baseline sin Kalman	—	—	—	—	—
Kalman $q = 10^{-5}, r = 10^{-2}$	—	—	—	—	—
Kalman $q = 10^{-4}, r = 10^{-2}$	—	—	—	—	—
Kalman $q = 10^{-3}, r = 10^{-2}$	—	—	—	—	—

4.3 Criterios para interpretar si los resultados son flojos

Un resultado se considera flojo si el F1 macro queda por debajo de 0.60 o si el recall macro queda por debajo de 0.50. En detección de anomalías, la accuracy por sí sola no es suficiente: un modelo puede lograr accuracy alta si predice casi todo como normal, pero fallar en detectar ataques.

Un resultado aceptable para una primera versión sería $F1_{macro} \geq 0.60$ y $Recall_{macro} \geq 0.50$. Un resultado bueno sería $F1_{macro} \geq 0.75$ con recall macro razonablemente alto.

4.4 Discusión esperada

La comparación con Kalman debe responder cuatro preguntas:

1. **Mejoro Kalman las métricas?** Si mejora F1 o MAE, significa que redujo ruido de predicción. Si empeora recall, probablemente suavizó demasiado y retrasó la detección de ataques.
2. **Hay trade-off entre precisión y recall?** Si Kalman reduce oscilaciones, puede eliminar falsos positivos, pero también puede retrasar subidas reales de probabilidad y aumentar falsos negativos.
3. **Que limitaciones tiene el random walk?** Supone que la probabilidad verdadera cambia lentamente. Ataques abruptos, de muy corta duración o patrones intermitentes pueden violar esta hipótesis.
4. **Que cambios se harían con más tiempo?** Tres propuestas concretas: ajustar umbral por validación en lugar de usar 0.5; probar ventanas 16, 32 y 64; reemplazar el Kalman escalar por un filtro con estado de tendencia; hacer búsqueda sistemática de q/r ; y estudiar explicabilidad por canales o frecuencias.

5 Conclusiones

La arquitectura propuesta cumple los cinco requisitos principales: usa una recurrencia de costo lineal en la longitud de la secuencia, estabiliza la dinámica mediante una matriz A con espectro negativo, extrae componentes periódicas con FFT, fusiona adaptativamente representaciones temporales y frecuenciales, y permite aplicar un filtro de Kalman como post-procesamiento. La entrega práctica queda lista para entrenar con los CSV de UNSW-NB15 y producir las tablas requeridas.